

TECH CHALLENGE • POSTECH FIAP • FASE 2

Classificando a Qualidade de Vinhos com Machine Learning

Uma leitura orientada a dados sobre o que torna um vinho tinto "Alta Qualidade" — e o que isso significa para o processo produtivo.

Storytelling da Análise Exploratória de Dados

Avaliar qualidade de vinho é caro, lento e subjetivo

Hoje

Especialistas avaliam aroma, sabor, acidez e equilíbrio manualmente — um processo sensorial.

O problema

Demorado, caro e sujeito à subjetividade de cada avaliador.

A oportunidade

Dados físico-químicos já coletados na produção podem prever a qualidade final.

Pergunta central: dá para prever se um vinho será "Alta Qualidade" só com dados físico-químicos?

1.599 vinhos tintos, 11 características físico-químicas

1.599

amostras de
vinho tinto

11

variáveis
físico-químicas

0

valores
faltantes

240


linhas
duplicadas

Variáveis disponíveis:

Acidez fixa · Acidez volátil · Ácido cítrico · Açúcar residual · Cloretos · Dióxido de enxofre livre · Dióxido de enxofre total · Densidade · pH · Sulfatos · Teor alcoólico

Fonte: Wine Quality Dataset (Kaggle/UCI) — Cortez et al., 2009, "Vinho Verde" português. Dados limpos: sem nulos; duplicadas tratadas no pré-processamento.

Vinhos "Alta Qualidade" são raros: só 14% da base



Nota ≥ 7 → Alta Qualidade


Nota < 7 → Baixa/Média Qualidade

86,4% dos vinhos são Baixa/Média Qualidade

13,6% são Alta Qualidade

Por que isso importa: um modelo "preguiçoso" já acertaria 86% só chutando sempre "Baixa/Média". Por isso a avaliação foca em precisão, recall e F1 da classe rara — não só em acurácia.

Três variáveis se destacam na relação com a qualidade



Teor alcoólico

correlação positiva mais forte — vinhos com mais álcool tendem a nota mais alta.



Sulfatos

conservante/antioxidante; mais presente em vinhos mais bem avaliados.



Acidez volátil

correlação negativa mais forte — indica defeito de fermentação (avinagemamento).

Quatro decisões antes de treinar qualquer modelo

1

Remover duplicadas

240 linhas idênticas removidas para não enviesar o aprendizado.

2

Novas variáveis

Razões entre acidez fixa/volátil e SO_2 livre/total, capturando equilíbrios relevantes.

3

Padronização


StandardScaler nas variáveis numéricas, necessário para a Regressão Logística.

4

Balanceamento (SMOTE)

Aplicado só no treino, gerando exemplos sintéticos de Alta Qualidade.


Três modelos testados — o Gradient Boosting teve o melhor equilíbrio



Modelo	F1 (Alta Qualidade)	ROC-AUC
Gradient Boosting	0,568	0,886
Random Forest	0,513	0,879
Regressão Logística	0,496	0,893

Gradient Boosting é o modelo recomendado: melhor equilíbrio entre encontrar vinhos de Alta Qualidade (recall) e acertar quando aponta um (precisão).

O modelo aprendeu o que a enologia já sabia



1º Teor alcoólico

Variável mais importante em todos os modelos testados.

2º Sulfatos

Conservante associado a maior estabilidade e nota.

3º Acidez volátil

Principal fator negativo — sinal de defeito de fermentação.

Três alavancas para o processo produtivo

Colheita e fermentação

Ajustar o ponto de colheita e a condução da fermentação para atingir teores alcoólicos mais altos (dentro do estilo do vinho).

Controle de contaminação

Priorizar o controle de temperatura e higiene que evitam a formação de acidez volátil (ácido acético).

Dosagem de sulfatos

Ajustar dentro dos limites regulatórios/sensoriais para ganhar estabilidade e qualidade percebida.

Uso recomendado: ferramenta de priorização (quais lotes merecem avaliação sensorial aprofundada), não substituto do enólogo.

EM RESUMO

Sim, dá para prever a qualidade do vinho com dados físico-químicos

Gradient Boosting foi o modelo mais equilibrado ($F1 = 0,57 \cdot \text{ROC-AUC} = 0,89$), com **teor alcoólico, sulfatos e acidez volátil** como principais variáveis explicativas — resultado coerente com o conhecimento enológico de domínio.

Repositório completo, notebook e código-fonte disponíveis no GitHub do projeto.